

Contenido

1. Introduccion	1
Prediccion de inundaciones	1
Incertidumbre en el proceso de Modelacion	1
Asimilacion de Datos	2
Hipotesis.	3
Objetivos	3
2. Metodolog a	4
Cadena de Markov	5
Bayes	5
Kalman lter	6
Ensemble Kalman Filter	7
3. Estado del arte	12
History	13

Indice de Figuras

2.1. Esquema de un tanque	4
2.2. Cadena de markov	5
2.3. Multiplicacion de dos gaussianas	6
2.4. Lorenz: baja varianza en el proceso del modelo	8
2.5. EnKF en lanzamiento parabolico	9
2.6. EnKF en lanzamiento parabolico	9
2.7. Lorenz: baja varianza en el proceso del modelo	10
2.8. Lorenz: ajuste de varianza en el proceso del modelo	11

1 Introduccion

Prediccion de inundaciones

Los eventos de inundacion extremos se caracterizan por presentar un inicio rapido y un tiempo de respuestas cortos, ademas, es dif icil predecir la magnitud, tiempo y lugar de ocurrencia. Por otro lado, los mecanismos generadores de este tipo de inundaciones, son pobremente entendidos. Debido a esto, la capacidad de tomar acciones, para reducir danos economicos y evitar la perdida de vidas, es limitada. Sin embargo, existen herramientas para la interpretacion y prediccion de este tipo de eventos, como los Modelos hidrologicos. La modelacion hidrologica comienza a ganar credibilidad en debido a metodos pioneros, desarrollados despues del siglo xx, como el metodo racional en (), y el metodo del hidrografa unitaria (sherman), estos avances en la teoria, de la mano con el avance de la capacidad computacional del siglo XX, ha hecho posible, la utilizacion de algoritmos mas complejos y potentes. En la actualidad, se buscan nuevas alternativas, desde Inteligencia artificial, asimilacion de datos.

Incertidumbre en el proceso de Modelacion

La capacidad de predecir de forma razonable el estado y la evolucion de las variables y parametros de un modelo hidrologico, depende en gran medida, de lograr representar conceptualmente y de forma acertada los procesos que se dan dentro de la cuenca, de la eleccion de las condiciones iniciales, de la correcta calibracion de los parametros y de la utilizacion de la mayor cantidad de informacion disponible, que puede provenir de diferentes fuentes. Hay que tener en cuenta, que los datos de entrada y salida de los modelos y la informacion obtenida por los sensores es imperfecta, es decir, tiene una incertidumbre asociada. Recientemente, varios autores han mostrado el beneficio de integrar el calculo de la incertidumbre en el proceso de modelacion. Algunos han desarrollado esquemas de analisis estadistico donde se puede obtener una adecuada cuantificacion de los errores asociados, tanto a los procesos (incertidumbre estructural), como a los datos de entrada y a los datos de salida. Tambien se han desarrollado estudios donde se cuantifica la incertidumbre en los parametros. En conjunto a lo anterior, es posible mejorar la prediccion teniendo en cuenta la incertidumbre de las diferentes fuentes de informacion (Reichle et al., 2002).

Asimilacion de Datos

La asimilacion de datos (DA), es un procedimiento que integra el conocimiento que se tiene del sistema, con las observaciones, sintetizando la informacion en un modelo dinamico (Houser et al., 2012). Una de las tecnicas de asimilacion mas utilizadas en hidrologia es el Ensemble Kalman Filter (EnKF) (Zhang et al., 2017), una adaptacion del Filtro Kalman (KF) (Kalman, 1960) para sistemas no lineales, propuesta por (Evensen, 1994)(Burgers et al., 1998).

El EnKF Es un filtro bayesiano usado para estimar probables estados del sistema basado en informacion previa. Aplicado a la modelacion hidrológica, corrige el estado del sistema actual a partir de los registros observados, con el fin de optimizar las condiciones iniciales del modelo sin la necesidad de afectar el esquema conceptual (Burgers et al., 1998). Desde su formulacion, el EnKF ha adquirido un creciente prestigio en prediccion en tiempo real en diferentes campos, clima, tsunamis, prediccion de inundaciones, etc, dada a su habilidad de caracterizar de manera acertada la incertidumbre.

A pesar de la eficacia del metodo de asimilacion, el desempeño de la prediccion esta limitado a la parametrizacion de los modelos. En el proceso de calibracion tipico de un modelo hidrológico, se utilizan datos historicos, se asume que los parametros son invariantes en el tiempo y se modifican hasta obtener soluciones similares a los datos observados. Este tipo de tecnica no tendra en cuenta informacion de futuras observaciones, ademas, centra la incertidumbre en los parametros, mas no en a los datos de entrada, salida, y a la estructura del modelo. Por esta razon, se han venido desarrollando nuevas estructuras como los filtros duales, que corrigen tanto los estados del sistema, como los parametros (Moradkhani et al., 2005).

ya que los metodos de calibracion convencionales atribuyen la incertidumbre del modelo (estructural), y de los datos de entrada, y salida, a la incertidumbre en los parametros.

Estos procedimientos de calibracion minimizan el error en la estimacion a partir de datos historicos, pero su esquema conceptual no tendra en cuenta los datos de observaciones futuras, ademas, asume que los parametros son invariantes en el tiempo, lo cual puede no llegar a ser correcto, por ejemplo, en cuencas con alta actividad antropica, donde es necesario recalibrar los parametros continuamente.

Se ha evaluado el beneficio de corregir la humedad del suelo con el EnKF en avenidas torrenciales y se han desarrollado diferentes esquemas con exito, demostrado la necesidad de evaluar varias propuestas para obtener un mejor desempeño segun el tipo de cuenca (Vergara et al., 2014).

teniendo en cuenta que existen pocas aplicaciones en cuencas tropicales con comportamiento torrencial, este tipo de tecnologías implementadas en este tipo de cuencas puede ser de gran utilidad dentro de un sistema de alertas tempranas.

Hipotesis.

En una cuenca tropical con características torrenciales es posible obtener mejoras en la predicción de caudales extremos mediante una metodología de asimilación.

Objetivos

Objetivo general

Evaluar la implementación de varios esquemas de asimilación mediante el EnKF, para optimizar parámetros y mejorar las condiciones iniciales de un modelo hidrológico, en diferentes escalas.

Objetivos específicos

- Desarrollar esquemas de asimilación para la optimización de variables de estado en un modelo hidrológico.
- Comparar el desempeño de los esquemas de asimilación en el cálculo de caudal y humedad del suelo, en diferentes escalas.
- Cuantificar la incertidumbre y la relación estadística entre las variables y parámetros involucrados en el proceso de modelación.
- Satellite remote sensing?

2 Metodología

Concepto de estado

Se define estado de un sistema como la mínima cantidad de información necesaria en un instante para que, conociendo la entrada a partir de ese instante, se pueda determinar la salida en cualquier instante posterior (Dominguez et al., 2000)




Figura 2.1: Esquema de un tanque

$$q(t) = V(t) = Ah(t)$$

$$\int_{-\infty}^t \frac{1}{A} q(\tau) d\tau = \int_{-\infty}^{t_0} \frac{1}{A} q(\tau) d\tau + \int_{t_0}^t \frac{1}{A} q(\tau) d\tau = h(t_0) + \int_{t_0}^t \frac{1}{A} q(\tau) d\tau$$

$$h(t) = \psi(t, t_0, h(t_0), u(\tau)), \quad t_0 \leq \tau < t$$

$$x(t) = \psi(t, t_0, x(t_0), u(\tau)), \quad t_0 \leq \tau < t \quad (2.1)$$

De esta forma se define el espacio de estado, siendo este el espacio vectorial en el cual

el vector de un estado toma valores, el cual se puede escribir de manera generalizada.

la teoría de estado representa un formalismo para el tratamiento y resolución de sistemas dinámicos deterministas. La evolución del sistema y la salida solo dependerán del estado actual, ya que $x(t)$ cuenta con la información del pasado.

función continua

$$\dot{x}(t) = f(t, x(t), u(t)) \quad (2.2)$$

$$y_k = \eta(t, x(t), u(t)) \quad (2.3)$$

Cadena de Markov

Se representa mediante dos fases:




Figura 2.2: Cadena de markov

Analisis

$$p(x, t \mid y_t) \quad (2.4)$$

Prediccion

$$p(x, t^+ \mid y_t) \quad (2.5)$$

Se utiliza el de Bayes para estimar la probabilidad de obtener cierto estado en el tiempo discreto t_k , dado el historial de las observaciones.

Bayes

$$p(x, t_k \mid y_{t_k}) \sim p(x, t_k \mid y_k, y_{t_{k-1}}) \quad (2.6)$$

Aplicando el teorema de probabilidad conjunta de bayes se tiene:

$$p(x, t_k | y_{t_k}) = \frac{p(y_k | x_k, y_{t_{k-1}})p(x, t_k | y_{t_{k-1}})}{p(y_k | y_{t_{k-1}})} \quad (2.7)$$




Figura 2.3: Multiplicación de dos gaussianas

Donde $p(y_k | x_k, y_{t_{k-1}})$ representa la probabilidad (likelihood), sea la función de distribución de probabilidad de los datos observados, $p(x, t_k | y_{t_{k-1}})$ es el estimado a priori. El denominador (Normalización), se puede representar de la siguiente manera.

$$p(y_t | y_{t_{k-1}}) = \int p(y_k | x)p(x, t_k | y_{t_{k-1}})dx$$

Kalman Iter

Las probabilidades se representan mediante funciones gaussianas, dada la facilidad de manipulación de estas, ya que el producto de dos gaussianas es otra gaussiana.

Algorithm

The algorithm is the same Bayesian Iter algorithm that we have used in every chapter. The update step is slightly more complicated, but I will explain why when we get to it.

Initialization

- Initialize the state of the Iter
- Initialize our belief in the state

Predict

- Use process model to predict state at the next time step
- Adjust belief to account for the uncertainty in prediction

Update

- Get a measurement and associated belief about its accuracy
- Compute residual between estimated state and measurement
- Compute scaling factor based on whether the measurement or prediction is more accurate
- set state between the prediction and measurement based on scaling factor
- update belief in the state based on how certain we are in the measurement

Ensemble Kalman Filter

$$x_{t+1}^{i-} = f(x_t^{i+}, u_t^i, \theta, t) + \omega_t^i, i = 1 \dots n, \omega_t^i \sim N(0, Q_t) \quad (2.8)$$

Donde x_{t+1}^{i-} es el estado del iesimo ensemble pronosticado para el tiempo $t + 1$, x_t^{i+} es el iesimo estado actualizado en el tiempo t y u_t^i las entradas. Ademas, con el fin de representar los errores del modelo, se agrega ruido mediante la matrix de covarianza $\omega_t^i \sim N(0, \Sigma_t^s)$ y se generan perturbaciones en las entradas ζ_t^i en cada paso del tiempo.

$$u_t^i = u_t + \zeta_t^i, \quad \zeta_t^i \sim N(0, R_{t+1}) \quad (2.9)$$

Para tener una varianza suficiente y evitar ..., las observaciones se deben tratar como variables aleatorias, usando la media como la actual observacion y con una covarianza definida. (Burgers et al., 1998).

los estados x_{t+1}^{i-} se actualizan usando el Gain K_{t+1}

Observation ensemble member

$$y_{t+1}^i = Hx_{t+1} + \varepsilon_{t+1}^i, \varepsilon_{t+1}^i \sim N(0, S_{t+1}) \quad (2.10)$$

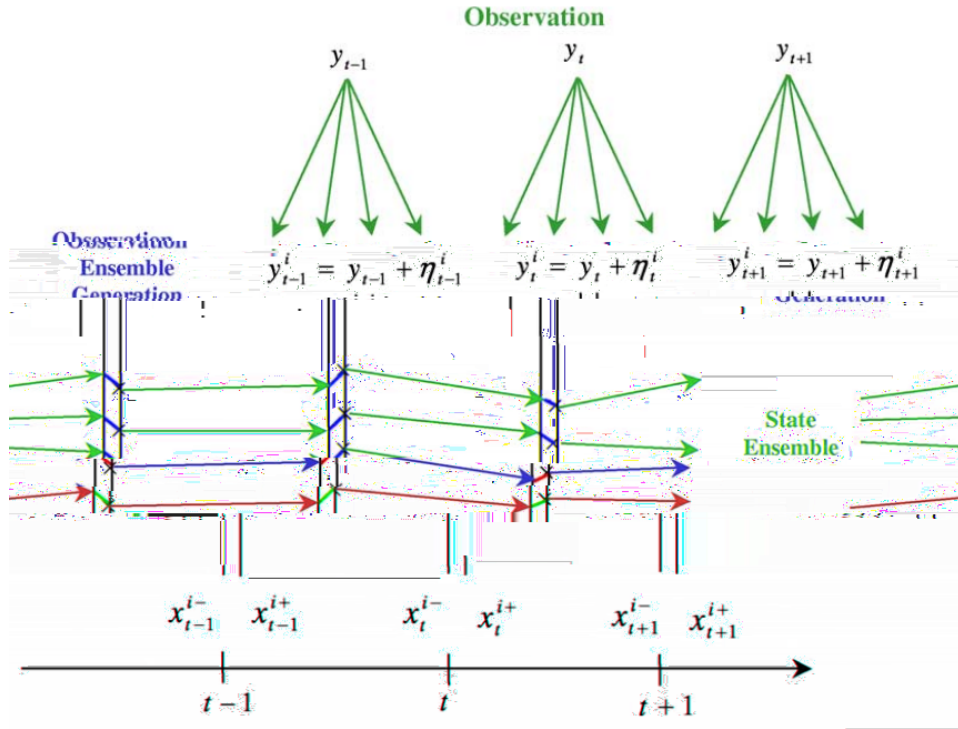


Figura 2.4: Lorenz: baja varianza en el proceso del modelo

$$x_{t+1}^{i+} = x_{t+1}^{i-} + K_{t+1}(y_{t+1}^i - Hx_{t+1}^{i-}) \quad (2.11)$$

$$K_{t+1} = P_{t+1}^- H^T (H P_{t+1}^- H^T + S_{t+1})^{-1} \quad (2.12)$$

$$P_{t+1}^- = \frac{1}{N-1} \sum_{i=1}^N [(x_{t+1}^{i-} - \langle x_{t+1}^- \rangle)(x_{t+1}^{i-} - \langle x_{t+1}^- \rangle)^T]^{-1} \quad (2.13)$$

$$\langle x_{t+1}^- \rangle = \frac{1}{N} \sum_{i=1}^N x_{t+1}^{i-} \quad (2.14)$$




Figura 2.5: EnKF en lanzamiento parabolico




Figura 2.6: EnKF en lanzamiento parabolico

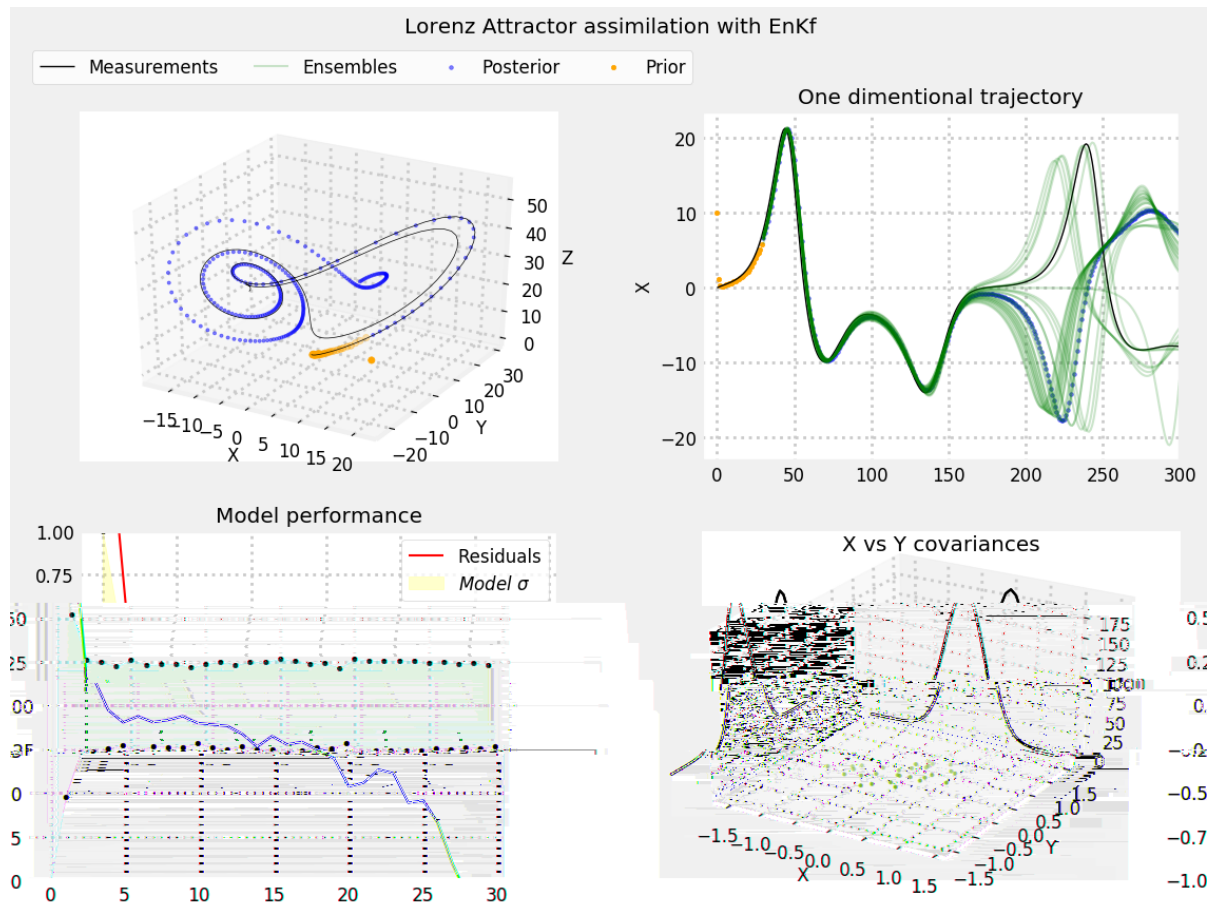


Figura 2.7: Lorenz: baja varianza en el proceso del modelo

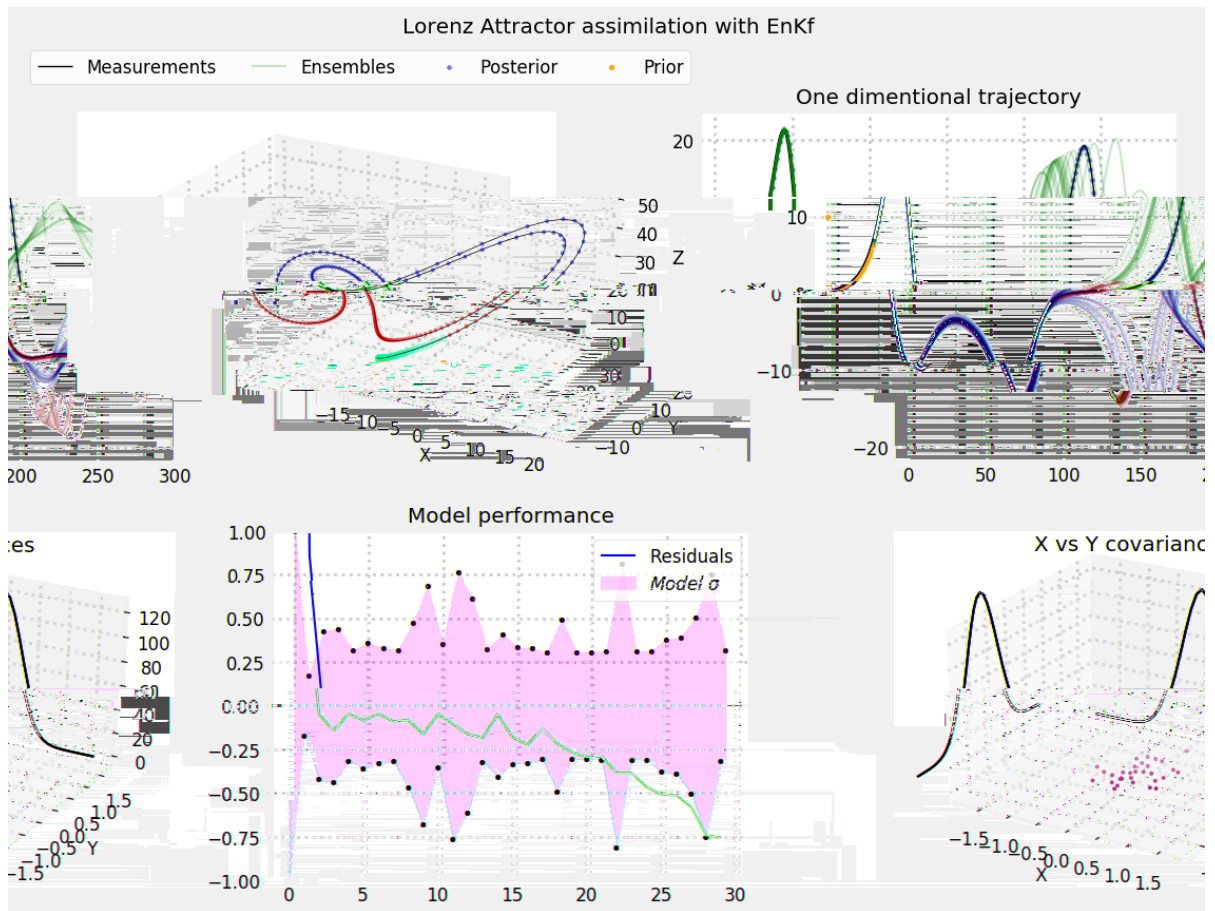


Figura 2.8: Lorenz: ajuste de varianza en el proceso del modelo

3 Estado del arte

Kalman history (Kalman, 1960)

- Lorenz 1963 Numerical solution of the convection equation (Lorenz, 1963)

EnKF evensen formaulation (Evensen, 1994)

- Solution of lorenz with EnKf (Evensen, 1997)

para que el analisis sea consistente y la varianza no sea muy pequena se deben tratar las observaciones como variables aleatorias. (Burgers et al., 1998)

- Control en el espacio de estado (Dominguez et al., 2000)

Ensemble Kalman evensen (Evensen, 2002)

dual in rainfall runo (Moradkhani et al., 2005) and (?).

Data assimilation for estimating the terrestrial water budget using a Constraint for water inbalance. also incorpora mas conocimiento del sistema hidrologico (Pan and Wood, 2006)

Real time food forecasting using ensemble kalman Iter (Srikanthan et al., 2007)

- state updating - parameter updating - dual EnKf

Pros and cons Enkf (?)

rst attempt integrates framework state and parameters, also simpli es tratment of forcing data (Liu and Gupta, 2007)

- Distributed schema: Corregir celdas aguas arriba mediante un factor de pesos. The correction factors are applied to correct stream ow variables for each cell located upstream of each gauging station, using as a weighting factor the area drained by each cell. (Da Paz et al., 2007)

assimilate stream ow (Clark et al., 2008)

Data assimilatiio for distributed hydrological catchment modeling via ensemble kallman Iter (Xie and Zhang, 2010)

localization (?)

state and parameter estimation of two land surface models usig the enkf and particle

- state augmentation - dual estimation (Zhang et al., 2017)

- Asimilacio en modelo mensual (Xiong et al., 2018)

Innovation method for ensemble Kalman filter in soil hydrology (Bauser et al., 2018)

History

Referencias

- Bauser, H. H., Berg, D., Klein, O., and Roth, K. (2018). In ation method for ensemble kalman lter in soil hydrology.
- Burgers, G., Jan van Leeuwen, P., and Evensen, G. (1998). Analysis scheme in the ensemble kalman lter. *Monthly weather review*, 126(6):1719{1724.
- Clark, M. P., Rupp, D. E., Woods, R. A., Zheng, X., Ibbitt, R. P., Slater, A. G., Schmidt, J., and Uddstrom, M. J. (2008). Hydrological data assimilation with the ensemble kalman lter: Use of stream ow observations to update states in a distributed hydrological model. *Advances in water resources*, 31(10):1309{1324.
- Da Paz, A. R., Collischonn, W., Tucci, C., Clarke, R., and Allasia, D. (2007). Data assimilation in a large-scale distributed hydrological model for mediumrange ow forecasts. *IAHS PUBLICATION*, 313:471.
- Dominguez, S., Campoy, P., and Sebastian, J. M. (2000). *Control en el espacio de estado*. Universidad Politecnica de Madrid, Escuela Tecnica Superior de Ingenieros Industriales.
- Evensen, G. (1994). Sequential data assimilation with a nonlinear quasi-geostrophic model using monte carlo methods to forecast error statistics. *Journal of Geophysical Research: Oceans*, 99(C5):10143{10162.
- Evensen, G. (1997). Advanced data assimilation for strongly nonlinear dynamics. *Monthly weather review*, 125(6):1342{1354.
- Evensen, G. (2002). Sequential data assimilation for nonlinear dynamics: the ensemble kalman lter. In *Ocean Forecasting*, pages 97{116. Springer.
- Evensen, G. (2003). The ensemble kalman lter: Theoretical formulation and practical implementation. *Ocean dynamics*, 53(4):343{367.
- Kalman, R. E. (1960). A new approach to linear ltering and prediction problems. *Journal of basic Engineering*, 82(1):35{45.
- Liu, Y. and Gupta, H. V. (2007). Uncertainty in hydrologic modeling: Toward an integrated data assimilation framework. *Water Resources Research*, 43(7).
- Lorenz, E. N. (1963). Deterministic nonperiodic ow. *Journal of the atmospheric sciences*, 20(2):130{141.

- Moradkhani, H., Sorooshian, S., Gupta, H. V., and Houser, P. R. (2005). Dual state{parameter estimation of hydrological models using ensemble kalman filter. *Advances in water resources*, 28(2):135{147.
- Pan, M. and Wood, E. F. (2006). Data assimilation for estimating the terrestrial water budget using a constrained ensemble kalman filter. *Journal of Hydrometeorology*, 7(3):534{547.
- Reichle, R. H., McLaughlin, D. B., and Entekhabi, D. (2002). Hydrologic data assimilation with the ensemble kalman filter. *Monthly Weather Review*, 130(1):103{114.
- Srikanthan, R., Amirthanathan, G., and Kuczera, G. (2007). Real-time flood forecasting using ensemble kalman filter. In *MODSIM 2007 International Congress on Modelling and Simulation. Modelling and Simulation Society of Australia and New Zealand*, pages 1789{1795. Citeseer.
- Vergara, H., Hong, Y., and Gourley, J. (2014). Improving flood forecasting skill with the ensemble kalman filter. *Revista de Tecnologia*, 13(1):9{27.
- Xie, X. and Zhang, D. (2010). Data assimilation for distributed hydrological catchment modeling via ensemble kalman filter. *Advances in Water Resources*, 33(6):678{690.
- Xiong, M., Liu, P., Cheng, L., Deng, C., Gui, Z., Zhang, X., and Liu, Y. (2018). Identifying time-varying hydrological model parameters to improve simulation efficiency by the ensemble kalman filter: A joint assimilation of stream flow and actual evapotranspiration. *Journal of Hydrology*.
- Zhang, H., Franssen, H.-J., Han, X., Vrugt, J. A., and Vereecken, H. (2017). State and parameter estimation of two land surface models using the ensemble kalman filter and the particle filter.